

短链平台运维与故障排查手册

用于 AskFlow 企业知识库 RAG 检索、PDF 解析、页码级 citation 与表格 chunk 测试

文档说明

本文档是一份用于企业知识库智能问答系统的样例 PDF，内容围绕短链平台的跳转链路、缓存策略、异步访问统计、限流保护和常见故障排查展开。文档刻意包含清晰标题、段落、列表和表格，便于测试 PDF 正文解析、表格结构化抽取、chunk 元数据保留、向量检索和页码级引用溯源。

适用场景

- 验证上传 PDF 后是否能够按页解析正文，并在 chunk 中保存 page_no 与 chunk_type。
- 验证用户提出 Redis 未命中、缓存击穿、RocketMQ 异步统计、Sentinel 限流等问题时，系统是否能召回正确片段。
- 验证表格内容是否可以被转为结构化 Markdown，并作为独立知识片段参与向量化和问答。
- 验证 RAG citations 是否能返回 document_name、chunk_id、page_no 与 chunk_type 等依据字段。

本手册不包含公司年假制度、财务报销流程、员工薪酬政策等内容。因此，当用户询问这些无依据问题时，系统应返回“知识库中没有检索到足够依据”，而不是强行生成答案。

一、短链跳转主链路

短链跳转是平台最高频的读请求链路。一次标准跳转请求通常从短码解析开始，系统根据 shortCode 查询短链配置，校验短链状态和过期时间，然后返回 HTTP 302 重定向到 originalUrl。为了降低数据库压力，跳转链路优先读取 Redis 缓存；当 Redis 未命中时，系统才回源 MySQL 查询，并在查询成功后回填 Redis。

跳转链路的关键步骤

- 根据 shortCode 构造 Redis key，例如 short_link:{shortCode}。
- 优先从 Redis 读取 originalUrl，命中后直接返回 302 重定向。
- Redis 未命中时回源 MySQL 查询短链记录，并校验 status、expireTime 和 originalUrl。
- MySQL 查询成功后，将 originalUrl 回填 Redis，后续同一短码请求可直接命中缓存。
- 如果短码不存在、短链被禁用、短链已过期或原始链接不可访问，应返回明确错误，不应继续跳转。

短链跳转失败的常见原因包括短码不存在、短链被禁用、短链已过期、原始链接不可访问，以及系统触发 Sentinel 限流。排查时应先确认请求短码是否正确，再检查短链状态、过期时间、Redis 缓存命中情况和 MySQL 中的原始记录。

二、Redis 未命中与缓存回填

当短链访问请求到达系统时，如果 Redis 没有查到原始链接，系统不能直接认为短链不存在，而应回源 MySQL 查询。MySQL 中存在有效短链记录时，需要将查询结果写回 Redis，这一步称为缓存回填。缓存回填能够减少后续请求对数据库的直接访问，是高频读场景中的基础优化。

Redis 未命中时的推荐处理策略如下：

- 先判断 Redis key 是否存在，若不存在则进入数据库回源逻辑。
- 回源 MySQL 后必须再次校验短链状态和过期时间，避免把无效短链写入缓存。
- 回填缓存时应设置合理 TTL，避免缓存长期保存过期或已禁用数据。
- 禁用短链或修改原始链接时，应主动删除 Redis 中的旧缓存，避免脏读。

三、缓存击穿与并发回源控制

当某个热点短链缓存刚好失效，大量请求同时到达并一起回源 MySQL 时，就可能出现缓存击穿。缓存击穿会导致数据库瞬时压力增大，严重时会影响跳转链路的稳定性。因此，在缓存失效瞬间大量请求同时回源数据库的场景下，应使用互斥锁或逻辑过期策略控制并发回源。

互斥锁方案

互斥锁的核心思想是同一时刻只允许一个请求回源 MySQL 查询并回填缓存，其余请求短暂等待、重试或返回降级结果。该方式实现简单，适合缓存重建成本较低但数据库压力敏感的场景。需要注意锁的过期时间，防止异常情况下锁无法释放。

逻辑过期方案

逻辑过期并不直接删除缓存，而是在缓存值中保存 logicalExpireTime。请求发现缓存逻辑过期后，可以先返回旧值，同时异步触发缓存重建。该方案能够避免大量请求阻塞在数据库回源路径上，更适合热点短链场景。

缓存击穿处理建议

- 普通短链可采用 Redis TTL + 回源回填。
- 热点短链建议引入互斥锁，避免同一短码被大量并发请求同时回源。
- 极热点短链可以使用逻辑过期，让用户请求优先返回旧缓存，同时异步刷新。
- 缓存更新与短链禁用、过期逻辑必须保持一致，避免缓存中保留无效 originalUrl。

四、访问统计为什么不适合同步写库

访问统计通常包括 PV、访问日志、IP、User-Agent、Referer 和访问时间等信息。这些数据对运营分析很重要，但不应该阻塞短链跳转主链路。短链跳转的核心目标是尽快完成 302 重定向，如果在主链路中同步写访问日志或更新统计表，会增加接口耗时，并在高并发下放大数据库写入压力。

因此，访问统计适合采用 RocketMQ 异步处理。跳转接口只负责发送访问事件消息，消费者在后台异步更新 PV 和访问日志。这样能够实现主链路和统计链路解耦，降低用户跳转延迟，并利用消息队列削峰。

五、RocketMQ 异步访问统计

RocketMQ 在短链访问统计中承担异步解耦和削峰作用。跳转接口在校验短链并返回 302 之前，将访问事件发送到 RocketMQ Topic；消费者订阅该 Topic 后，异步写入 short_link_access_log，并更新 short_link 表中的 PV 与 lastAccessTime。

访问事件消息体建议包含 eventId、shortLinkId、shortCode、originalUrl、clientId、userAgent、referer 和 accessTime。eventId 用于幂等控制，避免 RocketMQ 重试或重复投递导致 PV 重复累加和访问日志重复插入。

RocketMQ 统计链路优势

- 跳转主链路不再同步写访问日志，减少数据库写入对重定向耗时的影响。
- 高峰期访问事件先进入消息队列，消费者按照处理能力平稳消费，起到削峰作用。
- 通过 eventId 幂等校验，可以避免重复消费造成 PV 重复统计。
- 统计逻辑与跳转逻辑解耦，后续可以独立扩展 Referer 分布、UA 分布和 PV 趋势分析。

六、Sentinel 限流保护

Sentinel 用于保护高频接口，防止恶意访问或突发流量把系统压垮。短链平台中最需要保护的是短链跳转接口和短链创建接口。跳转接口流量高，容易被热点短码放大；创建接口虽然频率较低，但可能被恶意刷短链。

当触发 Sentinel 限流规则时，系统可以返回 429 Too Many Requests，提示用户稍后再试。对于后台创建接口，可以限制单用户或单 IP 的创建频率；对于公开跳转接口，可以按资源名或短码维度进行限流。

七、故障排查矩阵

下表用于测试 PDF 表格解析能力。理想情况下，pdfplumber 应将该表格识别为 TABLE 类型 chunk，并转为 Markdown 表格参与向量化。

故障现象	可能原因	排查动作	期望处理
短链无法跳转	短码不存在、短链禁用、已过期、原始链接不可访问	检查 short_code、status、expire_time、original_url	返回明确错误，不继续 302
Redis 未命中	缓存过期、缓存被主动删除、首次访问	回源 MySQL 查询有效短链并校验状态	查询成功后回填 Redis
缓存失效瞬间数据库压力升高	热点短链缓存击穿，大量请求同时回源	查看 Redis TTL、数据库 QPS、热点 shortCode	使用互斥锁或逻辑过期
访问统计拖慢跳转	PV 和日志同步写库，主链路被数据库写入阻塞	查看跳转接口耗时和数据库写入耗时	通过 RocketMQ 异步统计
PV 重复增加	MQ 消息重复消费或消费者重试	检查 eventId 是否唯一，访问日志是否重复	基于 eventId 做幂等校验
接口返回 429	Sentinel 限流规则被触发	检查资源名、QPS 阈值、访问峰值	限流保护生效，必要时调整阈值

表格中的“Redis 未命中”“缓存击穿”“RocketMQ 异步统计”“eventId 幂等”和“Sentinel 限流”是本知识库的核心检索关键词。用户使用缩写、短查询或语义改写提问时，Hybrid Retrieval 应能够召回这些片段。

八、RAG 评估问题建议

为了验证 AskFlow 对 PDF 文档的检索与引用能力，可以使用下列问题作为评估集。

- 问题：缓存里面没有查到原始链接时怎么办？
期望：应召回 Redis 未命中与回源 MySQL 片段。
- 问题：缓存失效瞬间大量请求同时访问数据库怎么处理？
期望：应召回缓存击穿、互斥锁或逻辑过期片段。
- 问题：为什么访问统计不要放在跳转接口同步写库？
期望：应召回 RocketMQ 异步统计与主链路解耦片段。
- 问题：RocketMQ 在短链访问统计中起什么作用？
期望：应回答异步处理访问事件、更新 PV 和访问日志。
- 问题：MQ 重复消费会导致什么问题？
期望：应召回 eventId 幂等控制，避免 PV 重复累加。
- 问题：Sentinel 限流会影响短链跳转吗？
期望：应说明限流会返回 429 或阻止请求继续进入核心链路。
- 问题：短链跳转失败有哪些原因？
期望：应包含短码不存在、禁用、过期、原始链接不可访问和限流。
- 问题：员工报销流程是什么？
期望：本文档无相关内容，系统应拒答或说明知识库没有依据。

九、面向页码级 citation 的要求

PDF 文档参与 RAG 问答时，citation 不应只返回文档名称和 chunkId，还应返回 page_no 与 chunk_type。这样用户看到答案后，可以直接定位到 PDF 的具体页码，并判断依据来自正文还是表格。对于企业知识库场景，这种可追溯性能够提升用户对答案的信任。

建议 citation 字段至少包含 document_name、chunk_id、page_no、chunk_type、score 和 content_preview。RAG Trace 中也应保留每个召回 chunk 的 page_no 和 source，便于排查低相关召回、重复上下文和引用错误。